## Ciencia de Datos para Políticas Públicas

Clase 04 - Manejo de Datos II

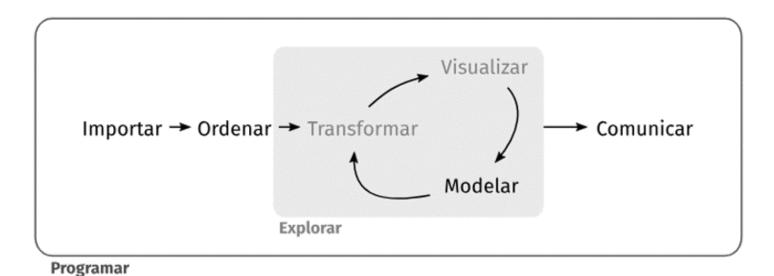
Pablo Aguirre Hormann 26/08/2020

## Antes de empezar

- Dudas
- Preguntas
- Comentarios

## ¿Qué veremos hoy?

- Un poco más de manejo de datos (dplyr)
- Transformación de datos (tidyr)
- Funciones e iteraciones



ifelse/case\_when

#### ifelse

### Se puede aplicar en data frames

```
datosONU tidy <- read csv("datos/DatosONU tidy.csv") %>%
  select(country name, year) %>%
  filter(year >= 2004, country name %in% c("Chile", "Argentina"))
datosONU tidy %>%
  mutate(nueva col = ifelse(year > 2005, 1, 0))
## # A tibble: 8 x 3
     country name year nueva col
                  <dbl>
                            <dbl>
##
     <chr>>
                   2004
## 1 Argentina
                                0
## 2 Argentina
                   2005
                                0
## 3 Argentina
                   2006
                                1
## 4 Argentina
                   2007
                                1
## 5 Chile
                   2004
                                0
## 6 Chile
                   2005
                                0
## 7 Chile
                   2006
                                1
## 8 Chile
                   2007
                                1
```

## ¿Y si queremos poner más de un valor?

```
datosONU tidy %>%
 mutate(nueva col = ifelse(year > 2005, 1, ifelse(year < 2005, 2, 0)))</pre>
## # A tibble: 8 x 3
     country name year nueva col
     <chr>
                  <dbl>
                            <dbl>
##
## 1 Argentina
               2004
## 2 Argentina
                   2005
                                0
## 3 Argentina
                   2006
                                1
                   2007
## 4 Argentina
                                 1
## 5 Chile
                   2004
## 6 Chile
                   2005
## 7 Chile
                   2006
                                1
## 8 Chile
                   2007
                                1
```

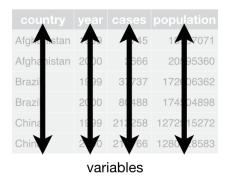
#### case\_when

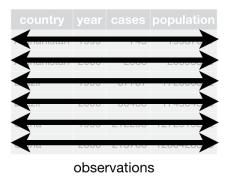
```
datosONU tidy %>%
  mutate(nueva_col = case_when(
    year > 2005 \sim 1,
    year < 2005 \sim 2,
    TRUE ~ 0
  ))
## # A tibble: 8 x 3
##
     country name year nueva col
    <chr>
                  <dbl>
                            <dbl>
##
## 1 Argentina
                2004
                                 2
## 2 Argentina
                   2005
                                 0
## 3 Argentina
                   2006
                                 1
## 4 Argentina
                   2007
                                 1
## 5 Chile
                   2004
                                 2
## 6 Chile
                   2005
                                0
## 7 Chile
                   2006
                                 1
## 8 Chile
                   2007
                                 1
```

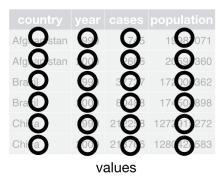
## Transformación de datos

## Tidy data - Datos ordenados

- Cada columna es una variable
- · Cada fila es una observación
- · Cada celda corresponde a un valor







#### tidyr

- pivot\_wider: transformar "datos largos" a "datos anchos"
- pivot\_longer: transformar "datos anchos" a "datos largos"
- separate: separa columnas
- · unite: une columnas

Más información en la web del paquete

## tidyr

#### Principales funciones (i)

• pivot\_wider

country	year	type	count		country	year	cases	pop
Α	1999	cases	0.7K		Α	1999	0.7K	19M
Α	1999	pop	19M	7	Α	2000	2K	20M
Α	2000	cases	2K		В	1999	37K	172M
Α	2000	pop	20M		В	2000	80K	174M
В	1999	cases	37K		С	1999	212K	1T
В	1999	pop	172M		С	2000	213K	1T
В	2000	cases	80K					
В	2000	pop	174M					
С	1999	cases	212K					
С	1999	pop	1T					
С	2000	cases	213K					
С	2000	pop	1T					

#### Pivot\_wider

table2

```
## # A tibble: 12 x 4
      country
##
                   year type
                                        count
                  <int> <chr>
##
      <chr>>
                                        <int>
   1 Afghanistan 1999 cases
                                          745
   2 Afghanistan
                  1999 population
                                     19987071
   3 Afghanistan
                   2000 cases
                                         2666
   4 Afghanistan
                   2000 population
                                     20595360
   5 Brazil
                   1999 cases
                                        37737
##
   6 Brazil
                   1999 population 172006362
   7 Brazil
                   2000 cases
                                        80488
                   2000 population 174504898
   8 Brazil
   9 China
                   1999 cases
                                       212258
                   1999 population 1272915272
## 10 China
## 11 China
                   2000 cases
                                       213766
## 12 China
                   2000 population 1280428583
```

```
## # A tibble: 6 x 4
                  year cases population
     country
     <chr>>
                 <int>
                       <int>
                                   <int>
## 1 Afghanistan
                  1999
                          745
                                19987071
## 2 Afghanistan
                  2000
                                20595360
                         2666
## 3 Brazil
                  1999
                       37737 172006362
## 4 Brazil
                  2000
                        80488 174504898
## 5 China
                  1999 212258 1272915272
## 6 China
                  2000 213766 1280428583
```

## tidyr

#### Principales funciones (ii)

• pivot\_longer

country	1999	2000		country	year	cases
Α	0.7K	2K	$\rightarrow$	Α	1999	0.7K
В	37K	80K		В	1999	37K
С	212K	213K		С	1999	212K
				Α	2000	2K
				В	2000	80K
				С	2000	213K

### Pivot\_longer

table4a

```
table4a %>%
 pivot_longer(2:3,
               names_to = "year",
               values to = "value")
## # A tibble: 6 x 3
    country
                 year
                        value
    <chr>
                 <chr> <int>
## 1 Afghanistan 1999
                         745
## 2 Afghanistan 2000
                         2666
## 3 Brazil
                        37737
                 1999
## 4 Brazil
                        80488
                 2000
## 5 China
                       212258
                 1999
## 6 China
                 2000
                      213766
```

Demo - Enfermedades respiratorias

#### Demo

#### Script

Clase04\_TransformacionDatosI.R

## Enfermedades respiratorias

glimpse(who)

```
## Rows: 7,240
## Columns: 60
  <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanis...
## $ country
  <chr> "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", ...
## $ iso2
  <chr> "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG"...
## $ iso3
## $ year
  <int> 1980, 1981, 1982, 1983, 1984, 1985, 1986, 1987, 1988, ...
## $ new sp m65
  ## $ new_sp f65
  ## $ new sn m65
```

#### Donde comenzamos

(enfermedades <- who %>%
 select(-iso2, -iso3))

```
## # A tibble: 7,240 x 58
##
      country year new sp m014 new sp m1524 new sp m2534 new sp m3544 new sp m4554
                                                     <int>
##
      <chr>>
              <int>
                           <int>
                                        <int>
                                                                   <int>
                                                                                <int>
    1 Afghan~ 1980
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    2 Afghan~ 1981
                                           NA
                             NA
                                                        NA
                                                                      NA
                                                                                   NA
    3 Afghan~ 1982
##
                             NA
                                           NA
                                                        NΑ
                                                                      NA
                                                                                   NA
##
    4 Afghan~ 1983
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    5 Afghan~ 1984
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    6 Afghan~ 1985
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    7 Afghan~ 1986
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    8 Afghan~ 1987
                             NA
                                           NA
                                                        NΑ
                                                                      NA
                                                                                   NA
    9 Afghan~ 1988
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
## 10 Afghan~ 1989
                             NA
                                           NA
                                                        NΑ
                                                                      NA
                                                                                   NΑ
## # ... with 7,230 more rows, and 51 more variables: new sp m5564 <int>,
## #
       new sp m65 <int>, new sp f014 <int>, new sp f1524 <int>,
       new sp f2534 <int>, new sp f3544 <int>, new sp f4554 <int>,
## #
       new_sp_f5564 <int>, new_sp_f65 <int>, new_sn_m014 <int>,
## #
## #
       new_sn_m1524 <int>, new_sn_m2534 <int>, new_sn_m3544 <int>,
## #
       new sn m4554 <int>, new sn m5564 <int>, new sn m65 <int>,
## #
       new sn f014 <int>, new sn f1524 <int>, new sn f2534 <int>,
## #
       new_sn_f3544 <int>, new_sn_f4554 <int>, new_sn_f5564 <int>,
## #
       new_sn_f65 <int>, new_ep_m014 <int>, new_ep_m1524 <int>,
## #
       new_ep_m2534 <int>, new_ep_m3544 <int>, new_ep_m4554 <int>,
## #
       new ep m5564 <int>, new ep m65 <int>, new ep f014 <int>,
## #
       new ep f1524 <int>, new ep f2534 <int>, new ep f3544 <int>,
## #
       new ep f4554 <int>, new ep f5564 <int>, new ep f65 <int>,
## #
       newrel m014 <int>, newrel m1524 <int>, newrel m2534 <int>,
## #
       newrel m3544 <int>, newrel m4554 <int>, newrel m5564 <int>,
       newrel m65 <int>, newrel f014 <int>, newrel f1524 <int>,
## #
```

## Donde queremos llegar

```
tabla_final
```

```
## # A tibble: 2 x 8
## # Groups: sexo [2]
           `0-14` `15-24` `25-34` `35-44` `45-54` `55-64` `65+`
    sexo
    <chr>>
                    <int>
                           <int>
                                  <int>
                                                   <int> <int>
             <int>
                                            <int>
             97051
                           495242 478700 417188
## 1 hombres
                   406084
                                                  325188 288063
## 2 mujeres
             99738 320620 347398 260839 184791 136441 129468
```

- · ¿Edad?
- · ¿Sexo?

## ¿Qué información tenemos disponible?

names(enfermedades)

```
[1] "country"
                                                      "new sp m1524" "new sp m2534"
                       "year"
                                       "new sp m014"
   [6] "new sp m3544" "new sp m4554" "new sp m5564" "new sp m65"
                                                                     "new_sp_f014"
## [11] "new_sp_f1524" "new_sp_f2534" "new_sp_f3544" "new_sp_f4554" "new_sp_f5564"
## [16] "new_sp_f65"
                       "new_sn_m014"
                                      "new sn m1524" "new sn m2534" "new sn m3544"
## [21] "new sn m4554" "new sn m5564" "new sn m65"
                                                      "new sn f014"
                                                                     "new sn f1524"
## [26] "new sn f2534" "new sn f3544" "new sn f4554" "new sn f5564" "new sn f65"
                       "new_ep_m1524" "new_ep_m2534" "new_ep_m3544" "new_ep_m4554"
## [31] "new ep m014"
## [36] "new_ep_m5564" "new_ep_m65"
                                      "new ep f014"
                                                      "new ep f1524" "new ep f2534"
                                                                     "newrel m014"
## [41] "new_ep_f3544" "new_ep_f4554"
                                      "new_ep_f5564" "new_ep_f65"
## [46] "newrel m1524" "newrel m2534" "newrel m3544" "newrel m4554" "newrel m5564"
                       "newrel f014"
                                      "newrel f1524" "newrel f2534" "newrel f3544"
## [51] "newrel m65"
## [56] "newrel f4554" "newrel f5564" "newrel f65"
```

• [new o new\_]+[enfermedad]+[\_]+[sexo]+[RangoEdad]

## ¿Pivot\_ ... longer o wider?

#### enfermedades

```
## # A tibble: 7,240 x 58
##
      country year new sp m014 new sp m1524 new sp m2534 new sp m3544 new sp m4554
##
      <chr>
              <int>
                          <int>
                                        <int>
                                                     <int>
                                                                   <int>
                                                                                <int>
    1 Afghan~
               1980
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
##
    2 Afghan~
              1981
                             NA
                                                                                   NA
##
                                           NA
                                                        NA
                                                                      NA
##
    3 Afghan~
              1982
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
##
    4 Afghan~
               1983
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
    5 Afghan~
              1984
                                                                                   NA
##
                             NA
                                           NA
                                                        NA
                                                                      NA
##
    6 Afghan~
               1985
                                                                      NA
                                                                                   NA
                             NA
                                                        NA
                                           NA
    7 Afghan~
              1986
                                                                                   NA
##
                             NA
                                                        NA
                                                                      NA
                                           NA
##
    8 Afghan~
               1987
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
##
    9 Afghan~
               1988
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
## 10 Afghan~
              1989
                             NA
                                           NA
                                                        NA
                                                                      NA
                                                                                   NA
## # ... with 7,230 more rows, and 51 more variables: new sp m5564 <int>,
## #
       new sp m65 <int>, new sp f014 <int>, new sp f1524 <int>,
## #
       new sp f2534 <int>, new sp f3544 <int>, new sp f4554 <int>,
## #
       new sp f5564 <int>, new sp f65 <int>, new sn m014 <int>,
## #
       new_sn_m1524 <int>, new sn m2534 <int>, new sn m3544 <int>,
## #
       new sn m4554 <int>, new sn m5564 <int>, new sn m65 <int>,
## #
       new sn f014 <int>, new sn f1524 <int>, new sn f2534 <int>,
## #
       new sn f3544 <int>, new sn f4554 <int>, new sn f5564 <int>,
## #
       new sn f65 <int>, new ep m014 <int>, new ep m1524 <int>,
```

¿Pivot\_ ... longer o wider?

#### Transformamos la forma de nuestros datos

```
(enfermedades2 <- enfermedades %>%
  pivot_longer(-c(country:year),
               names to = "variables",
               values to = "valores"))
## # A tibble: 405,440 x 4
      country
                  vear variables
                                     valores
      <chr>
                  <int> <chr>
##
                                       <int>
   1 Afghanistan 1980 new sp m014
                                          NΑ
   2 Afghanistan 1980 new_sp_m1524
                                          NA
   3 Afghanistan 1980 new_sp_m2534
                                          NA
   4 Afghanistan 1980 new sp m3544
                                          NA
   5 Afghanistan 1980 new sp m4554
                                          NA
   6 Afghanistan 1980 new sp m5564
                                          NA
   7 Afghanistan 1980 new_sp_m65
                                          NΑ
   8 Afghanistan 1980 new_sp_f014
                                          NΑ
   9 Afghanistan 1980 new sp f1524
                                          NA
## 10 Afghanistan 1980 new sp f2534
                                          NA
## # ... with 405,430 more rows
```

· Tenemos una columna que contiene tres variables pero también una parte que no nos sirve mucho.

## stringr

#### Reference

#### Pattern matching

str\_count() Count the number of matches in a string

str\_detect() Detect the presence or absence of a pattern in a string

str\_extract() Extract matching patterns from a string

str\_extract\_all()

str\_locate() str\_locate\_all() Locate the position of patterns in a string

str\_match() str\_match\_all()
Extract matched groups from a string

# Eliminaremos parte de la columna "variables" que no nos sirve

```
(enfermedades3 <- enfermedades2 %>%
  mutate(variables = str remove(variables, "new "),
        variables = str remove(variables, "new")))
## # A tibble: 405,440 x 4
                  year variables valores
      country
      <chr>
                  <int> <chr>
                                   <int>
   1 Afghanistan 1980 sp m014
                                      NA
   2 Afghanistan 1980 sp_m1524
                                      NA
   3 Afghanistan 1980 sp m2534
                                      NA
   4 Afghanistan 1980 sp m3544
                                      NA
   5 Afghanistan 1980 sp m4554
                                      NA
   6 Afghanistan 1980 sp_m5564
                                      NA
   7 Afghanistan 1980 sp_m65
                                      NA
   8 Afghanistan 1980 sp f014
                                      NA
   9 Afghanistan 1980 sp f1524
                                      NA
## 10 Afghanistan 1980 sp f2534
                                      NΑ
## # ... with 405,430 more rows
```

· Ahora tenemos una columna que contiene tres variables. ¿Cómo las separamos?

#### separate (i)

#### enfermedades3

```
## # A tibble: 405,440 x 4
##
      country
                   vear variables valores
##
      <chr>>
                  <int> <chr>
                                    <int>
   1 Afghanistan 1980 sp_m014
                                       NΑ
   2 Afghanistan 1980 sp_m1524
                                       NA
    3 Afghanistan 1980 sp m2534
                                       NA
   4 Afghanistan 1980 sp m3544
                                       NA
   5 Afghanistan 1980 sp m4554
                                       NA
   6 Afghanistan 1980 sp m5564
                                       NA
   7 Afghanistan 1980 sp m65
                                       NA
    8 Afghanistan 1980 sp f014
                                       NA
   9 Afghanistan 1980 sp f1524
                                       NA
## 10 Afghanistan 1980 sp f2534
                                       NA
## # ... with 405,430 more rows
```

```
(enfermedades4 <- enfermedades3 %>%
  separate(variables,
           into = c("enfermedad", "otro"),
           sep = "_"))
## # A tibble: 405,440 x 5
                   year enfermedad otro valores
      country
      <chr>>
                  <int> <chr>
##
                                   <chr>>
                                           <int>
   1 Afghanistan 1980 sp
                                   m014
                                              NA
   2 Afghanistan 1980 sp
                                   m1524
                                              NA
   3 Afghanistan 1980 sp
                                   m2534
                                              NA
   4 Afghanistan 1980 sp
                                   m3544
                                              NA
   5 Afghanistan 1980 sp
                                   m4554
                                              NA
## 6 Afghanistan 1980 sp
                                   m5564
                                              NA
## 7 Afghanistan 1980 sp
                                   m65
                                              NA
## 8 Afghanistan 1980 sp
                                   f014
                                              NA
## 9 Afghanistan 1980 sp
                                   f1524
                                              NA
## 10 Afghanistan 1980 sp
                                   f2534
                                              NA
## # ... with 405,430 more rows
```

#### separate (ii)

enfermedades4

```
## # A tibble: 405,440 x 5
                   year enfermedad otro valores
##
      country
##
      <chr>>
                  <int> <chr>
                                   <chr>>
                                           <int>
   1 Afghanistan 1980 sp
                                   m014
                                              NΑ
    2 Afghanistan 1980 sp
                                   m1524
                                              NA
    3 Afghanistan 1980 sp
                                   m2534
                                              NA
   4 Afghanistan 1980 sp
                                   m3544
                                              NA
   5 Afghanistan 1980 sp
                                   m4554
                                              NA
   6 Afghanistan 1980 sp
                                   m5564
                                              NA
   7 Afghanistan 1980 sp
                                   m65
                                              NA
    8 Afghanistan 1980 sp
                                   f014
                                              NA
   9 Afghanistan 1980 sp
                                   f1524
                                              NA
## 10 Afghanistan 1980 sp
                                   f2534
                                              NA
## # ... with 405,430 more rows
```

```
(enfermedades5 <- enfermedades4 %>%
  separate(otro,
           into = c("sexo", "edad"),
           sep = 1)
## # A tibble: 405,440 x 6
      country
                   year enfermedad sexo edad valores
      <chr>>
                  <int> <chr>
##
                                   <chr> <chr>
                                                 <int>
   1 Afghanistan 1980 sp
                                         014
                                                    NA
   2 Afghanistan 1980 sp
                                         1524
                                                    NA
                                   m
   3 Afghanistan 1980 sp
                                   m
                                         2534
                                                    NA
   4 Afghanistan 1980 sp
                                         3544
                                                    NA
                                   m
   5 Afghanistan 1980 sp
                                         4554
                                                    NA
   6 Afghanistan 1980 sp
                                         5564
                                                    NA
                                   m
## 7 Afghanistan 1980 sp
                                         65
                                                    NA
   8 Afghanistan 1980 sp
                                         014
                                                    NA
   9 Afghanistan 1980 sp
                                   f
                                         1524
                                                    NA
## 10 Afghanistan 1980 sp
                                         2534
                                                    NA
## # ... with 405,430 more rows
```

## Se podría llegar a lo mismo usando stringr

```
enfermedades2 %>%
  transmute(country, year,

  enfermedad = case_when(
    str_detect(variables, "rel") ~
    str_sub(variables, 4, 6),
    TRUE ~ str_sub(variables, 5,6)),

sexo = case_when(
    str_detect(variables, "m") ~ "m",
    TRUE ~ "f"),

edad = str_extract(variables, "\\d+"),
    valores
)
```

```
## # A tibble: 405,440 x 6
                  year enfermedad sexo edad valores
      country
##
      <chr>
                 <int> <chr>
                                  <chr> <chr>
                                               <int>
  1 Afghanistan 1980 sp
                                        014
                                                  NA
   2 Afghanistan 1980 sp
                                       1524
                                                  NA
  3 Afghanistan 1980 sp
                                       2534
                                                  NA
## 4 Afghanistan 1980 sp
                                        3544
                                                  NA
## 5 Afghanistan 1980 sp
                                       4554
                                                  NA
## 6 Afghanistan 1980 sp
                                       5564
                                                  NA
## 7 Afghanistan 1980 sp
                                       65
                                                  NA
## 8 Afghanistan 1980 sp
                                       014
                                                  NA
   9 Afghanistan 1980 sp
                                       1524
                                                  NA
## 10 Afghanistan 1980 sp
                                        2534
                                                  NA
## # ... with 405,430 more rows
```

## Modificaremos algunos valores para mayor claridad

```
(enfermedades6 <- enfermedades5 %>%
  mutate(
    edad = case_when(
        edad == "014" ~ "0-14",
        edad == "1524" ~ "15-24",
        edad == "2534" ~ "25-34",
        edad == "3544" ~ "35-44",
        edad == "4554" ~ "45-54",
        edad == "5564" ~ "55-64",
        edad == "65" ~ "65+"
    ),
    sexo = case_when(
        sexo == "m" ~ "hombres",
        sexo == "f" ~ "mujeres"
    )))
```

```
## # A tibble: 405,440 x 6
                   vear enfermedad sexo
      country
                                          edad valores
      <chr>>
                  <int> <chr>
                                   <chr>>
                                          <chr>>
                                                  <int>
## 1 Afghanistan 1980 sp
                                   hombres 0-14
                                                     NA
## 2 Afghanistan 1980 sp
                                   hombres 15-24
                                                     NA
    3 Afghanistan 1980 sp
                                   hombres 25-34
                                                     NA
   4 Afghanistan 1980 sp
                                   hombres 35-44
                                                     NA
   5 Afghanistan 1980 sp
                                   hombres 45-54
                                                     NA
   6 Afghanistan 1980 sp
                                   hombres 55-64
                                                     NA
   7 Afghanistan 1980 sp
                                   hombres 65+
                                                     NA
   8 Afghanistan 1980 sp
                                   mujeres 0-14
                                                     NA
   9 Afghanistan 1980 sp
                                   mujeres 15-24
                                                     NA
## 10 Afghanistan 1980 sp
                                   mujeres 25-34
                                                     NA
## # ... with 405,430 more rows
```

# Calculamos el total de enfermedades por sexo y rango de edad

```
(resumen enfermedades <- enfermedades6 %>%
  filter(year == 2010) %>%
  group_by(sexo, edad) %>%
  summarise(total = sum(valores, na.rm = TRUE)))
## # A tibble: 14 x 3
## # Groups:
              sexo [2]
##
      sexo
              edad
                     total
      <chr>
             <chr> <int>
   1 hombres 0-14
                     97051
   2 hombres 15-24 406084
   3 hombres 25-34 495242
   4 hombres 35-44 478700
   5 hombres 45-54 417188
   6 hombres 55-64 325188
   7 hombres 65+
                   288063
   8 mujeres 0-14
                     99738
   9 mujeres 15-24 320620
## 10 mujeres 25-34 347398
## 11 mujeres 35-44 260839
## 12 mujeres 45-54 184791
## 13 mujeres 55-64 136441
## 14 mujeres 65+ 129468
```

#### Pivot\_wider para dar la forma final a la tabla

```
(tabla final <- resumen enfermedades %>%
 pivot wider(names from = edad, values from = total))
## # A tibble: 2 x 8
## # Groups:
              sexo [2]
           `0-14` `15-24` `25-34` `35-44` `45-54` `55-64` `65+`
##
    sexo
##
    <chr>>
             <int>
                   <int>
                           <int>
                                  <int> <int>
                                                  <int> <int>
## 1 hombres 97051 406084
                           495242 478700 417188
                                                  325188 288063
## 2 mujeres 99738 320620
                           347398
                                   260839
                                          184791 136441 129468
```

#### Resumen

```
tabla_final <- who %>%
 # Eliminar columnas que no usaremos
  select(-iso2, -iso3) %>%
 # Ajustar forma de los datos (de ancho a largo)
  pivot longer(-c(country:year), names to = "variables", values to = "valores", values drop na = TRUE) %>%
 # Extraer información de la columna "variables
 mutate(variables = str remove(variables, "new "),
         variables = str remove(variables, "new")) %>%
  separate(variables, into = c("enfermedad", "otro"), sep = "_") %>%
  separate(otro, into = c("sexo", "edad"), sep = 1) %>%
 # Re-codificar las columnas edad y sexo
 mutate(edad = case_when(
    edad == "014" \sim "0-14",
    edad == "1524" ~ "15-24",
    edad == "2534" ~ "25-34",
    edad == "3544" ~ "35-44",
    edad == "4554" ~ "45-54",
    edad == "5564" ~ "55-64",
    edad == "65" \sim "65+"),
    sexo = case_when(
      sexo == "m" ~ "hombres",
      sexo == "f" ~ "mujeres")) %>%
  # Generar tabla final para el año 2010
 filter(year == 2010) %>%
  group_by(sexo, edad) %>%
  summarise(total = sum(valores, na.rm = TRUE)) %>%
  pivot_wider(names_from = edad, values_from = total)
```

## Ejercicio

## **Ejercicio**

#### Script

· Clase04\_EjercicioI.R

## Funciones e iteraciones

#### **Funciones**

- Hasta ahora hemos visto funciones que vienen por defecto en R o en paquetes que cargamos
- Pero también podemos generar nuestras propias funciones
  - ¿Para qué?
- · Si se encuentran con un script que repite muchas veces (¿más de 3?) probablemente sea necesaria una función

# ¿Cómo se crea una función?

- Una función tiene tres partes
  - Nombre
  - Argumentos
  - Cuerpo

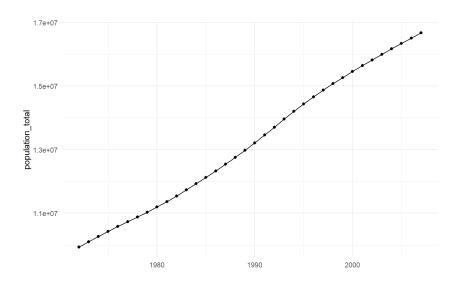
```
ElevaryDividir <- function(x, y, z){
   (x^y)/z
}
ElevaryDividir(3, 2, 4)
## [1] 2.25</pre>
```

# Ejemplo

Estamos explorando datos y queremos ir graficando distintos indicadores para distintos países

```
datosONU_tidy <- read_csv("datos/DatosONU_tidy.csv")

datosONU_tidy %>%
  filter(country_name == "Chile") %>%
  ggplot(aes(x = year, y = population_total)) +
  geom_point() +
  geom_line() +
  labs(x = NULL) +
  theme_minimal()
```

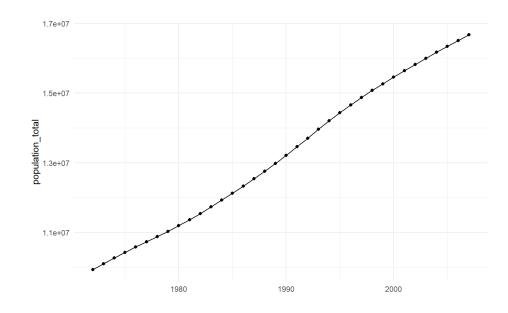


## Crear una función que haga esto

```
graf_indicador_pais <- function(x, y){
  y <- enquo(y)

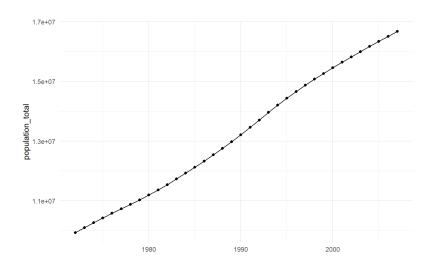
  datosONU_tidy %>%
  filter(country_name == x) %>%
  ggplot(aes(x = year, y = !!y)) +
  geom_point() +
  geom_line() +
  labs(x = NULL) +
  theme_minimal()
}
```

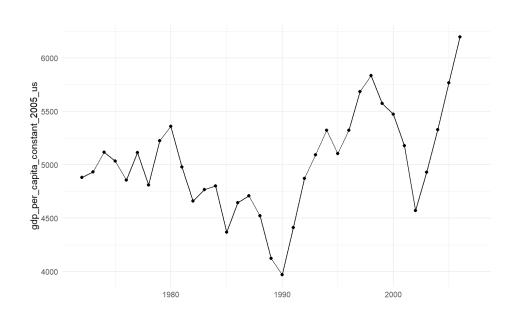
graf\_indicador\_pais("Chile", population\_total)



# Y ahora podemos hacer muchas cosas más

graf\_indicador\_pais("Chile", population\_total)





#### **Iteraciones**

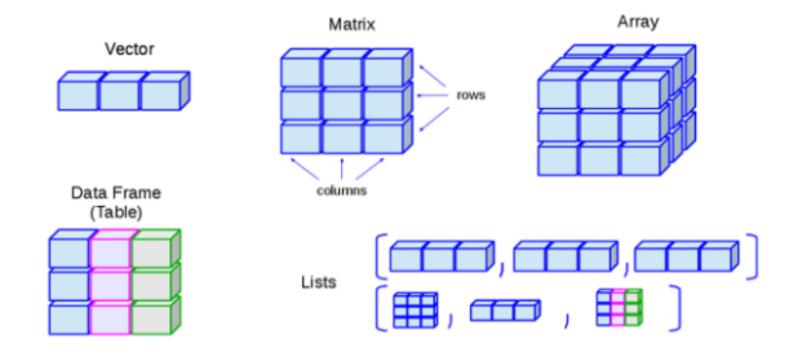
#### ¿Para qué?

Digamos que queremos graficar el mismo indicador para varios países:

```
graf_indicador_pais("Chile", gdp_per_capita_constant_2005_us)
graf_indicador_pais("Argentina", gdp_per_capita_constant_2005_us)
graf_indicador_pais("United States", gdp_per_capita_constant_2005_us)
```

## Antes de seguir

#### Tipos de objetos



## for loops

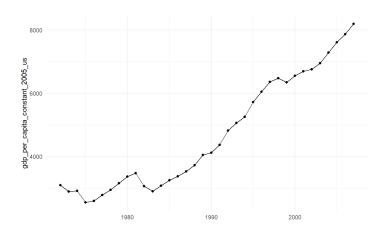
```
for (i in 1:10){
   print(2^i)
}

## [1] 2
## [1] 4
## [1] 8
## [1] 16
## [1] 32
## [1] 64
## [1] 128
## [1] 512
## [1] 512
## [1] 1024
```

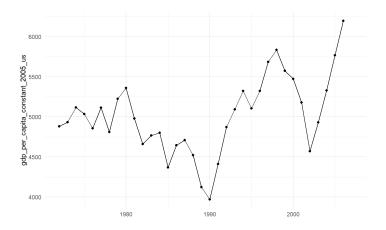
### for loop aplicado a nuestro ejemplo

```
graficos <- list()
paises <- c("Chile", "Argentina", "United States")
for (i in seq_along(paises)){
   graficos[[i]] <- graf_indicador_pais(paises[i], gdp_per_capita_constant_2005_us)
}</pre>
```

graficos[[1]]



graficos[[2]]



# Otra opción

#### map

```
library(purrr)
paises <- c("Chile", "Argentina", "United States")
graficos <- map(paises, graf_indicador_pais, gdp_per_capita_constant_2005_us)</pre>
```

#### graficos[[1]]



#### graficos[[2]]



#### Funciones map

- map(): resultado es una lista
- map\_lgl(): resultado es un vector de valores lógicos
- map\_int(): resultado es un vector de números integrales
- map\_dbl(): resultado es un vector de números decimales
- map\_chr(): resultado es un vector de valores tipo texto

# Ejercicio

# **Ejercicio**

#### Script

· Clase04\_EjercicioII.R

#### ¿Qué se viene?

- Próxima clase: regresión vs clasificación
- · Tarea 2: sábado 5 de septiembre
- · Vayan recopilando sus datos
  - 21 de septiembre: 1ra entrega